

# 1 随机事件和概率

## 随机事件及其运算

### 基本定义

随机试验具有**可重复性**、**可能结果多样性**、**不可预测性**。

随机试验  $E$  所有可能的结果组成的集合称为**样本空间**，记作  $\Omega$ ；样本空间的元素，也就是随机试验  $E$  的直接结果，称为**样本点**，记作  $\omega$ 。

在随机试验中可能发生也可能不发生的事件称为**随机事件**，用大写英文字母  $A, B, C$  记录。随机事件的本质是样本点的集合，也就是  $\Omega$  的子集，因此有：

$$A \subseteq \Omega \implies A \text{ 为随机事件}$$

同时，

$$\text{随机事件 } A \text{ 发生} \iff \omega \in A$$

随机事件是单点集，则称作**基本事件**；是全集  $\Omega$ ，称为**必然事件**；是空集  $\emptyset$ ，称为**不可能事件**。

### 随机事件的运算及运算律

1.  $A \subseteq B \iff (\forall \omega)(\omega \in A \rightarrow \omega \in B)$ ，即  $A$  发生  $B$  一定发生。
2.  $A = B \iff A \subseteq B \wedge B \subseteq A$ ，即  $A, B$  同时发生。
3. 和事件  $A \cup B$ ，也记作  $A + B$ ，即  $A \cup B$  发生，则  $A, B$  至少其一发生。

多个事件的和事件  $\bigcup_{i=1}^n A_i$ ， $n$  可以为  $+\infty$ 。

4. 积事件  $A \cap B$ ，也记作  $AB$ ，即  $A \cap B$  发生，则  $A, B$  必共同发生。

多个事件的积事件  $\bigcap_{i=1}^n A_i$ ， $n$  可以为  $+\infty$ 。

5. **互不相容**（互斥事件）若  $AB = \emptyset$ ，则称  $A, B$  互不相容（或为互斥事件）。

若  $A_1, A_2, \dots, A_n$  两两互斥，即为  $A_i A_j = \emptyset (i, j = 1, 2, \dots, n)$ ， $n$  可以为  $+\infty$ 。

6. **逆事件**（对立事件）若  $A \cap B = \emptyset, A \cup B = \Omega$ ，则称  $B$  是  $A$  的对立事件（逆事件），记作  $\bar{A} = B$ 。

7. **差事件**  $A - B$ ，即  $A$  发生且  $B$  不发生，即  $A\bar{B}$ 。

**运算律**（和集合论类似）

1. 吸收律： $A \cup \Omega = \Omega, A \cap \Omega = A, A \cup \emptyset = A, A \cap \emptyset = \emptyset, A \cup (AB) = A, A \cap (A + B) = A$ ；
2. 重余律： $\bar{\bar{A}} = A$ ；
3. 幂等律： $A \cup A \cup \dots \cup A = A, A \cap A \cap \dots \cap A = A$ ；
4.  $A - B = A\bar{B} = A - AB$ ；
5. 交换律： $A \cap B = B \cap A, A \cup B = B \cup A$ ；
6. 结合律： $A \cup (B \cup C) = (A \cup B) \cup C, A \cap (B \cap C) = (A \cap B) \cap C$ ；
7. 分配律： $(A \cup B) \cap C = (A \cap C) \cup (B \cap C), (A \cap B) \cup C = (A \cup C) \cap (B \cup C)$ ；
8. 对偶律： $\overline{A \cup B} = \bar{A} \cap \bar{B} = \bar{A}\bar{B}, \overline{A \cap B} = \bar{A} \cup \bar{B} = \bar{A} \cup \bar{B}$ ；

对偶律可以推广： $\overline{\bigcup_{i=1}^n A_i} = \bigcap_{i=1}^n \bar{A}_i, \overline{\bigcap_{i=1}^n A_i} = \bigcup_{i=1}^n \bar{A}_i$ 。

# 概率

事件  $A$  发生的可能性大小数值估量称为  $A$  的概率，记作  $P(A)$ 。

## 古典概型

特点： $\Omega$  仅有有限个样本点，每个基本事件发生的可能性大小相同。若满足这两条性质，则为古典概型。

记  $n = \#\Omega, k = \#A$  分别表示总基本事件个数以及组成  $A$  的基本事件个数，那么有**古典概型概率公式**：

$$P(A) = \frac{k}{n} = \frac{\#A}{\#\Omega}$$

## 几何概型

设  $\Omega$  为一个有界区域上的所有点， $A$  为  $\Omega$  上任意子区域，在  $\Omega$  中完全随机任意取点，则取点落入  $A$  的概率为

$$P(A) = \frac{m(A)}{m(\Omega)}$$

其中， $m(\cdot)$  为测度；在一维平面上， $m(A) = l_A$  为  $A$  长度；二维平面上， $m(A) = S_A$  为区域  $A$  面积。

此时我们称上面这种概型为**几何概型**。

**【注意】**  $\forall a \in \Omega, P(\{a\}) = 0$ ，说明**概率为0的事件不一定为不可能事件；但不可能事件概率为0**。

## 统计概率

设  $A \subseteq \Omega$ ，在相同条件下重复试验  $n$  次，其中  $A$  发生了  $n_A$  次，则称

$$f_n(A) = \frac{n_A}{n}$$

为  $A$  在这  $n$  次试验中发生的**频率**。频率有如下性质：

- $f_n(A) \in [0, 1]$ ;
- $f_n(\Omega) = 1, f_n(\emptyset) = 0$ ;
- 可加性：若  $A_1, A_2, \dots, A_n$  两两互斥，则  $f_n(\cup_{i=1}^n A_i) = \sum_{i=1}^n f_n(A_i)$ ;
- **频率具有稳定性**。

**概率的统计定义** 在相同条件下重复进行的  $n$  次试验中，事件  $A$  发生的频率稳定在一常数  $p$  附近，在其附近摆动，且随着  $n$  增大而摆动越小，称  $p$  为  $A$  发生概率，记作  $P(A) = p$ 。

## 概率的公理化定义

设  $\mathcal{F}$  为所有事件的全体，即为**事件域**（集合的集合）。

定义集函数  $P(\cdot) : \mathcal{F} \rightarrow \mathbb{R}$ ，将每一个事件  $A$  映射到一个概率  $P(A)$  上。

**概率的公理化定义**  $(\Omega, \mathcal{F})$  上的概率实质上是  $\mathcal{F}$  上满足下列三条的集函数：

- **非负性**： $\forall A \in \mathcal{F}, P(A) \geq 0$ ;
- **归一性**： $P(\Omega) = 1$ ;
- **可列可加性**：若  $A_1, A_2, \dots, A_n, \dots$  为可列的两两互斥事件，则

$$P(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$$

则称  $(\Omega, \mathcal{F}, P)$  为**概率空间**。显然,  $(\Omega, \mathcal{F})$  上的概率不唯一。

## 概率的基本性质

- $P(\emptyset) = 0$ ;

证明: 利用可列可加性: 由于  $\emptyset \cup \emptyset \cup \dots \cup \emptyset = \emptyset$ , 从而  $P(\emptyset) = \sum_{i=1}^{\infty} P(\emptyset)$ , 因此  $P(\emptyset) = 0$ 。

- **有限可加性**: 设  $A_1, A_2, \dots, A_n$  为两两互斥事件, 则

$$P(\cup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$$

证明: 利用可列可加性, 令  $A_{n+1} = A_{n+2} = \dots = \emptyset$ , 则

$P(\cup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i) + \sum_{i=n+1}^{\infty} 0$ 。得证。

- $0 \leq P(A) \leq 1, P(A) = 1 - P(\bar{A})$ ;

证明: 利用有限可加性和归一性,  $1 = P(\Omega) = P(A) + P(\bar{A})$ 。

- $\forall A, B \in \mathcal{F}, P(B - A) = P(B) - P(AB) = P(A \cup B) - P(A)$ ;

证明: 由于  $B = (B - A) + AB, A \cup B = (B - A) + A$ , 利用有限可加性即可。

- 特别地, 若  $A \subseteq B$ , 则  $P(B - A) = P(B) - P(A)$ ;

- $\forall A, B \in \mathcal{F}$ ,

$P(A \cup B) = P(A) + P(B - A) = P(A) + P(B) - P(AB) \leq P(A) + P(B)$ ; 称为**次可加性或概率的加法公式**。

- $\forall A, B, C \in \mathcal{F}$ ,

$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC)$ , 称为**容斥原理或多除少补原理**。

## 条件概率

### 基本定义

一般地,  $\forall A, B \in \mathcal{F}, P(A) > 0$ , 则称  $P(B|A)$  为事件  $A$  发生的条件下, 事件  $B$  发生的**条件概率**, 定义为

$$P(B|A) = \frac{P(AB)}{P(A)}$$

则  $P(\cdot|A)$  为  $(\Omega, \mathcal{F})$  上集函数, 容易验证满足概率公理化定义三条性质, 因此  $P(\cdot|A)$  是  $(\Omega, \mathcal{F})$  上的一种概率, 具有上节中叙述的概率的全部性质。

### 乘法公式

由条件概率定义可得乘法公式:

$$P(AB) = P(A)P(B|A) = P(B)P(A|B)$$

以及推广的乘法公式:

$$P(A_1 A_2 \dots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \dots P(A_n|A_1 A_2 \dots A_{n-1})$$

### 全概率公式

一般把  $A$  设为所关心事件,  $B_1, B_2, \dots, B_n$  为  $n$  种可能情况, 若满足:

- $\Omega = \cup_{i=1}^n B_i$ ;
- $B_i B_j = \emptyset (i, j = 1, 2, \dots, n, i \neq j)$

则

$$P(A) = \sum_{i=1}^n P(B_i)P(A|B_i)$$

## Bayes 公式

一般把  $A$  设为所关心事件,  $B_1, B_2, \dots, B_n$  为  $n$  种可能情况, 若满足:

- $\Omega = \cup_{i=1}^n B_i$ ;
- $B_i B_j = \emptyset$  ( $i, j = 1, 2, \dots, n, i \neq j$ )

则

$$P(B_i|A) = \frac{P(AB_i)}{P(A)} = \frac{P(B_i)P(A|B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}$$

## 事件的独立性

若  $P(B|A) = P(B)$ , 则称  $A$  对  $B$  **没有影响**; 如果  $A$  对  $B$  没有影响且  $B$  对  $A$  没有影响, 则  $A, B$  **互不影响**。

设  $A, B \in \mathcal{F}$ , 若  $P(AB) = P(A)P(B)$ , 则称事件  $A, B$  **相互独立**。

### 独立的性质

- $\Omega$  和  $\emptyset$  和任何事件都独立;
- 若  $A, B$  独立, 则  $A, \bar{B}, \bar{A}, B, \bar{A}, \bar{B}$  独立。
- 如  $0 < P(A) < 1$ , 则  $A, B$  独立  $\iff P(B|A) = P(B|\bar{A}) = P(B)$ 。
- 若  $P(A)P(B) > 0$  则  $A, B$  互不相容  $\implies A, B$  不相互独立

证明: 若  $A, B$  互不相容, 则  $P(AB) = 0 < P(A)P(B)$ , 从而不相互独立。

### 独立性的判定

- 利用定义,  $P(AB) = P(A)P(B)$ 。
- 利用性质3, 若  $P(B|A) = P(B)$  或  $P(B|\bar{A}) = P(B)$ , 则  $A, B$  相互独立。
- 由题意判断  $A, B$  是否存在影响。

**$n$  个事件的独立性** 若  $n$  个事件  $A_1, A_2, \dots, A_n$  满足如下式子

$$\begin{aligned} P(A_i A_j) &= P(A_i)P(A_j) (1 \leq i < j \leq n) \\ P(A_i A_j A_k) &= P(A_i)P(A_j)P(A_k) (1 \leq i < j < k \leq n) \\ &\vdots \\ P(A_1 A_2 \dots A_n) &= P(A_1)P(A_2) \dots P(A_n) \end{aligned}$$

则称  $A_1, A_2, \dots, A_n$  **相互独立**。

**$n$  个事件独立性的判定** 两种方法, ① 由定义; ② 由题意判定。

**$n$  个事件独立性的性质** 若  $A_1, A_2, \dots, A_n$  相互独立, 则将  $n$  个事件分成  $k$  组, 对每组事件进行求和、积、差、逆等运算后得到的  $k$  个事件也相互独立。

## 2 随机变量及其分布

### 随机变量

设  $E$  是随机试验,  $\Omega$  为  $E$  样本空间,  $\mathcal{F}$  为事件域, 若有单实值函数  $X(\cdot): \Omega \rightarrow \mathbb{R}$ , 即  $\forall x, \{\omega: X(\omega) \leq x\} \in \mathcal{F}$ , 则称  $X(\omega)$  为**随机变量**。

分类：离散、非离散（其中一类为连续型）

设  $X$  为随机变量，则  $\forall x \in \mathbb{R}$ ，**分布函数** 定义为  $F(x) \stackrel{\text{def}}{=} P(\{X \leq x\})$ 。

### 分布函数的性质

- $0 \leq F(x) \leq 1, F(+\infty) = 1, F(-\infty) = 0$ ;
- **单调不减**:  $\forall x_1 < x_2, F(x_1) \leq F(x_2)$ ;
- **右连续性**:  $F(x+0) = F(x)$ 。

**分布函数的判定** 任意函数满足上述三条即可作为分布函数。

**分布函数的其他性质** 若  $X$  分布函数  $F(x)$ ，则

- $P(a \leq X \leq b) = F(b) - F(a-0)$ ;
- $P(a < X < b) = F(b-0) - F(a)$ ;
- $P(X = a) = F(a) - F(a-0)$ 。

## 离散型随机变量

### 基本定义

若随机变量  $X$  所有可能取值为有限个或可列无穷多个，则称  $X$  为**离散型随机变量**；用**分布列/分布律**描述分布：

$$P(X = x_i) = p_i \quad (i = 1, 2, 3, \dots, n, \dots)$$

$X$	$x_1$	$x_2$	...	$x_n$
$P$	$p_1$	$p_2$	...	$p_n$

一般令  $x_1, x_2, \dots, x_n, \dots$  递增。

离散型随机变量的分布函数：

$$F(x) = P(X \leq x) = \sum_{x_k \leq x} P(X = x_k)$$
$$P(X = x_k) = p_k = P(x_{k-1} < X \leq x_k) = F(x_k) - F(x_{k-1})$$

### 常见分布

**两点分布（0-1分布）** 若随机变量  $X$  满足

$$P(X = k) = p^k(1-p)^{1-k}, (k = 0, 1)$$

则称  $X$  服从参数为  $p$  的0-1分布。

**二项分布（伯努利分布）** 独立重复做  $n$  次试验，每次有  $p$  概率成功， $1-p$  概率失败，最后成功次数  $X$  服从的分布即为二项分布。即若  $X$  分布列满足：

$$P(X = k) = C_n^k p^k (1-p)^{n-k} (k = 0, 1, \dots, n)$$

此时称  $X$  服从二项分布，记作  $X \sim B(n, p)$ 。可以发现两点分布即为  $n = 1$  的二项分布  $B(1, p)$ 。

**二项分布的最可能取值** 若  $X \sim B(n, p)$ ，则若  $(n+1)p$  为整数，概率在  $k = (n+1)p - 1$  与  $k = (n+1)p$  取最大值，否则  $((n+1)p$  非整数) 概率在  $k = [(n+1)p]$  取最大值，其中  $[\cdot]$  意为取整。

**Poisson分布（泊松分布）** 若随机变量  $X$  分布列为  $P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!} (k = 0, 1, 2, \dots)$ ，则称  $X$  服从参数为  $\lambda$  的泊松分布，记作  $X \sim \pi(\lambda)$  或  $X \sim P(\lambda)$ 。

**Poisson定理** 设  $\lim_{n \rightarrow \infty} np_n = \lambda > 0$ , 则对于固定  $k$ , 有

$$\lim_{n \rightarrow \infty} C_n^k p_n^k (1 - p_n)^{n-k} = e^{-\lambda} \frac{\lambda^k}{k!} \quad (k = 0, 1, 2, \dots)$$

当  $n > 100, p < 0.05$  时可以认为  $C_n^k p_n^k (1 - p_n)^{n-k} \approx e^{-\lambda} \frac{\lambda^k}{k!}$ 。

## 连续型随机变量

### 基本定义

设  $X$  是一随机变量,  $X \sim F(x)$ , 若  $\exists f(x)$ , 使得  $\forall x \in \mathbb{R}, F(x) = P(X \leq x) = \int_{-\infty}^x f(u)du$ , 则称  $X$  为**连续型随机变量**, 称  $f(x)$  为概率密度函数。显然连续型随机变量的分布函数  $F(x)$  绝对连续且唯一, 概率密度函数  $f(x)$  不唯一。

### 概率密度函数的性质

- $f(x) > 0$ ;
- $\int_{-\infty}^{+\infty} f(x)dx = F(+\infty) = 1$ ;
- $f(x)$  连续点时有  $F'(x) = f(x)$ ;
- $f(x_0)\Delta x \approx P(x_0 < X \leq x_0 + \Delta x)$ ;
- $P(a < X \leq b) = P(a < X < b) = P(a \leq X < b) = P(a \leq X \leq b) = F(b) - F(a)$ ;
- $\forall k, P(X = k) = 0$ 。

**概率密度函数的判定** 满足性质1, 2的函数即可作为概率密度函数。

### 常见分布

**区间  $(a, b)$  上的均匀分布** 若  $X$  的密度函数  $f(x)$  满足:

$$f(x) = \begin{cases} \frac{1}{b-a} & (x \in (a, b)) \\ 0 & (x \notin (a, b)) \end{cases}$$

则称  $X$  满足区间  $(a, b)$  上的均匀分布, 记作  $X \sim U(a, b)$ 。其分布函数  $F(x)$  为:

$$F(x) = \begin{cases} \frac{x-a}{b-a} & (x \in (a, b)) \\ 0 & (x \leq a) \\ 1 & (x \geq b) \end{cases}$$

**指数分布** 若  $X$  的密度函数  $f(x)$  为

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & (x \geq 0) \\ 0 & (x < 0) \end{cases}$$

则称  $X$  满足参数为  $\lambda$  的指数分布, 记作  $X \sim E(\lambda)$ 。其分布函数  $F(x)$  为

$$F(x) = \begin{cases} 1 - e^{-\lambda x} & (x \geq 0) \\ 0 & (x < 0) \end{cases}$$

### 指数分布的性质

- $P(a < X < b) = e^{-\lambda a} - e^{-\lambda b}$ ;
- **无记忆性**: 若  $X \sim E(\lambda)$ , 则  $P(t < X \leq t + \Delta t | X > t) = P(0 < X \leq \Delta t) \quad (\Delta t > 0)$ 。

**正态分布** 若随机变量  $X$  的密度函数  $f(x)$  为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

则称  $X$  服从参数为  $\mu, \sigma^2$  的正态分布, 记为  $X \sim N(\mu, \sigma^2)$ 。其分布函数  $F(x)$  为超越函数。

**标准正态分布** 随机变量  $X \sim N(0, 1)$ , 则其分布函数  $\varphi(x)$  为

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

分布函数  $\Phi(x)$  满足  $\Phi(x) + \Phi(-x) = 1$ , 因此 (标准) 正态分布具有对称性。标准正态分布函数可以查表。

**正态分布转化为标准正态分布** 若  $X \sim N(\mu, \sigma^2)$ , 则  $\frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

## 随机变量函数的分布

### 离散型随机变量函数的分布

**一般方法** 设  $X$  是离散型随机变量,  $Y = g(X)$ , 则求  $Y$  的分布的一般方法如下:

- $Y = y_1, y_2, \dots, y_k$  (求出  $Y$  所有可能取值);
- $P(Y = y_i) = P(g(X) = y_i) = \sum_{g(x_j)=y_i} p_j$ 。

### 连续型随机变量函数的分布

**一般方法** 设  $X$  是连续性随机变量,  $Y = g(X)$ , 则求  $Y$  分布的一般方法如下:

- 先求分布函数  $F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = \int_{g(x) \leq y} f_X(x) dx$ ;
- 对于  $y$  求导即得概率密度函数  $f_Y(y) = \frac{d}{dy} F_Y(y)$ 。

**定理** 设  $X$  具有概率密度函数  $f_X(x)$ ,  $g(x)$  为  $\mathbb{R}$  上严格单调可导函数, 则  $Y = g(X)$  密度函数为

$$\begin{aligned} f_Y(y) &= |h'(y)| f_X(h(y)) \quad (y \in (\alpha, \beta)) \\ f_Y(y) &= 0 \quad (y \notin (\alpha, \beta)) \end{aligned}$$

## 3 多维随机变量及其分布

### 二维随机变量及其分布

设  $E$  是随机试验,  $\Omega$  为  $E$  样本空间,  $\mathcal{F}$  为事件域, 若函数  $X \times Y: \Omega \rightarrow \mathbb{R}^2$ , 则称  $(X, Y)$  为**二维随机变量**。

**联合分布函数** 设  $(X, Y)$  为二维随机变量,  $\forall (x, y)$ ,  $F(x, y) \stackrel{\text{def}}{=} P(X \leq x, Y \leq y)$  为二维随机变量  $(X, Y)$  的联合分布函数。

**联合分布函数的性质**

- $0 \leq F(x, y) \leq 1, F(+\infty, +\infty) = 1, F(\cdot, -\infty) = F(-\infty, \cdot) = 0$ ;
- $F(x, y)$  对于  $x, y$  均单调不减; 即固定  $x$  (或  $y$ ),  $F(x, y)$  关于  $y$  (或  $x$ ) 单调不减;
- 对  $x, y$  均右连续, 即  $F(x_0, y) = F(x_0, y+0), F(x, y_0) = F(x+0, y_0)$ ;
- 对任意  $a < b, c < d$ , 有

$$F(b, d) - F(b, c) - F(a, d) + F(a, c) = P(a < X \leq b, c < Y \leq d) \geq 0$$

**联合分布函数的判定** 满足上述四条性质的  $F(x, y)$  可以称为联合分布函数。

**边缘分布函数** 设  $(X, Y)$  联合分布函数为  $F(x, y)$ , 则  $X, Y$  各自的分布函数称为边缘分布函数, 为

$$F_X(x) = F(x, +\infty), F_Y(y) = F(+\infty, y)$$

联合分布函数唯一确定边缘分布函数, 反之不真。

## 二维离散型随机变量

若二维随机变量的所有可能取值为有限多个或无穷可列多个, 则称  $(X, Y)$  为**二维离散型随机变量**。  
 $(X, Y)$  的联合分布律 (联合分布列) 为:

$$P(X = x_i, Y = y_j) = p_{i,j} \quad (i, j = 1, 2, \dots)$$

Y/P/X	$x_1$	$x_2$	...	$x_n$
$y_1$	$p_{1,1}$	$p_{2,1}$	...	$p_{n,1}$
$y_2$	$p_{1,2}$	$p_{2,2}$	...	$p_{n,2}$
...	...	...	...	...
$y_m$	$p_{1,m}$	$p_{2,m}$	...	$p_{n,m}$

**性质**  $p_{i,j} > 0$ ,  $\sum_i \sum_j p_{i,j} = 1$ 。

**判定** 若满足如上性质可作为二维离散型随机变量的联合分布列。

**边缘分布列**  $P(Y = y_j) = \sum_i p_{i,j}$ ,  $P(X = x_i) = \sum_j p_{i,j}$ 。

## 二维连续型随机变量

**基本定义** 设  $(X, Y)$  联合分布函数  $F(x, y)$ , 若  $\exists f(x, y) \geq 0$ , 使得  
 $\forall x, y, F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(x, y) dx dy$ , 则称  $(X, Y)$  为二维连续型随机变量,  $f(x, y)$  称为其联合密度函数。

**联合密度函数的性质**

- $f(x, y) \geq 0$ ;
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(u, v) du dv = F(+\infty, +\infty) = 1$ ;
- 设  $G$  为平面上区域, 则  $P((x, y) \in G) = \iint_G f(u, v) dS$ ;
- 若  $f(x, y)$  在  $(x_0, y_0)$  处二元连续, 则  
 $f(x_0, y_0) = \frac{\partial^2}{\partial x \partial y} F(x, y)|_{x=x_0, y=y_0} = \frac{\partial^2}{\partial y \partial x} F(x, y)|_{x=x_0, y=y_0}$ 。

**联合密度函数的判定** 满足性质1, 2的函数即可作为联合密度函数。

**边缘密度函数**  $f_X(x) = F'_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$ ,  $f_Y(y) = F'_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$ 。

**常见分布**

**均匀分布** 设  $D$  为平面上一个有界区域, 若  $f(x, y)$  满足

$$f(x, y) = \frac{1}{S_D} ((x, y) \in D)$$
$$f(x, y) = 0 ((x, y) \notin D)$$

则称  $(X, Y)$  服从区域  $D$  上均匀分布, 记作  $(X, Y) \sim U(D)$ 。

**二维正态分布** 若  $(X, Y)$  具有概率密度

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}[(\frac{x-\mu_1}{\sigma_1})^2 - 2\rho(\frac{x-\mu_1}{\sigma_1})(\frac{y-\mu_2}{\sigma_2}) + (\frac{y-\mu_2}{\sigma_2})^2]}$$

其中,  $\sigma_1 > 0, \sigma_2 > 0, \rho \in (-1, 1)$ 。

则称  $(X, Y)$  服从参数为  $\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho$  的二维正态分布, 记作  $(X, Y) \sim N(\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho)$ 。



则边缘密度函数  $f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}$ ,  $f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(y-\mu_2)^2}{2\sigma_2^2}}$ 。

注 若  $X, Y$  均服从正态分布, 那么  $(X, Y)$  不一定服从二维正态分布!

反例  $f(x, y) = \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}} (1 + \sin x \sin y)$ , 容易发现  $X, Y \sim N(0, 1)$ 。

## 二维随机变量的条件分布

问题 已知  $(X, Y)$  联合分布, 求  $X = x_0$  下  $Y$  的分布。

### 二维离散型随机变量

一般方法 设  $P(X = x_i, Y = y_j) = p_{i,j}$ , 且  $p_{i,\cdot} = P(X = x_i) = \sum_j p_{i,j} > 0$ , 则

$$P(Y = y_j | X = x_i) = \frac{P(X = x_i, Y = y_j)}{P(X = x_i)} = \frac{p_{i,j}}{p_{i,\cdot}} = \frac{p_{i,j}}{\sum_{j'} p_{i,j'}}$$

### 二维连续型随机变量

一般方法 设  $(X, Y) \sim f(x, y)$ ,  $X \sim f_X(x)$ ,  $Y \sim f_Y(y)$ , 则  $X = x$  下  $Y$  分布为:

$$F_Y(y | X = x) = \frac{\int_{-\infty}^y f(x, t) dt}{f_X(x)}$$
$$f_Y(y | X = x) = \frac{f(x, y)}{f_X(x)}$$

注:  $F_{X|Y}(x|y)$ ,  $f_{X|Y}(x|y)$  是  $x$  的函数,  $y$  为常数!

性质

- $f_X(x | Y = y_0) = k f(x, y_0)$ , 则  $k = \frac{1}{f_Y(y_0)}$ ;
- 连续情况下的条件概率乘法公式  $f(x, y) = f_X(x) f_{Y|X}(y|x) = f_Y(y) f_{X|Y}(x|y)$ ;
- 连续情况下的全概率公式  $f_X(x) = \int_{-\infty}^{+\infty} f_Y(y) f_{X|Y}(x|y) dy$ ;
- 二维正态分布的条件分布仍然是正态分布!

## 随机变量的独立性

### 离散型随机变量

对二维离散型随机变量, 若满足对于任意  $(x_i, y_j)$  都有  $P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$ , 即  $p_{i,j} = p_{i,\cdot} p_{\cdot,j}$ , 则称  $X, Y$  **互相独立**。

若  $X, Y$  互相独立, 则  $P(X = x_i | Y = y_j) = P(X = x_i)$ , 即已知  $Y$  取值不影响  $X$  的分布。

### 连续型随机变量

设  $(X, Y)$  联合密度函数  $f(x, y)$ , 边缘密度函数  $f_X(x)$ ,  $f_Y(y)$ , 若  $f(x, y) = f_X(x) f_Y(y)$  在  $f(x, y)$  的连续点都成立, 则称  $X, Y$  **互相独立**。

**独立性质及判定:**  $X, Y$  独立  $\iff f_X(x|Y = y) = f_X(x) \iff f_Y(y|X = x) = f_Y(y)$ 。

**独立必要条件:** 区域为直矩形区域 (根据定义可得)。

**判定定理** 设  $f(x, y)$  为  $(X, Y)$  联合密度函数, 则  $X, Y$  相互独立的充要条件为存在非负可积  $r(x), g(y)$ , 使得  $f(x, y) = r(x)g(y)$  在  $f(x, y)$  一切连续点成立。

**二维正态分布独立的判定**  $\rho = 0$ 。

## 一般随机变量

一般地, 若对任意  $x, y$  均有  $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y)$ , 即  $F(x, y) = F_X(x)F_Y(y)$ , 则称  $X, Y$  **互相独立**。实际上, 该定义等价于任意选取一个矩形区域满足相乘条件 (即等价于  $\forall a < b, c < d$ , 有  $P(a \leq X \leq b, c \leq Y \leq d) = P(a \leq X \leq b)P(c \leq Y \leq d)$ )。

**等价描述** 实际上, 还等价于  $\forall B_x, B_y, P(X \in B_x, Y \in B_y) = P(X \in B_x)P(Y \in B_y)$ 。

**性质** 如果  $X, Y$  独立, 则随机变量的函数  $g(X), h(Y)$  独立。

**随机变量相互独立性推广为  $n$  维** 如果  $n$  维随机变量  $(X_1, X_2, \dots, X_n)$  满足

- $P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n) = \prod_{i=1}^n P(X_i \leq x_i)$
- 或  $F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F_{X_i}(x_i)$

则称  $X_1, X_2, \dots, X_n$  相互独立。

## 多维随机变量函数的分布

### 离散型随机变量

**具有可加性的两个分布的叠加**

- 若  $X_1 \sim B(n, p), X_2 \sim B(m, p)$ , 则  $X_1 + X_2 \sim B(n + m, p)$ ;
- 若  $X_1 \sim P(\lambda_1), X_2 \sim P(\lambda_2)$ , 则  $X_1 + X_2 \sim P(\lambda_1 + \lambda_2)$ 。

**一般方法** 当  $(X, Y)$  为离散型随机变量时,  $Z = g(X, Y)$  也是离散型随机变量, 其中

$$P(Z = z_k) = P(g(X, Y) = z_k) = \sum_{g(x_i, y_j) = z_k} P(X = x_i, Y = y_j) = \sum_{g(x_i, y_j) = z_k} p_{i,j}$$

### 连续型随机变量

**一般方法** 当  $(X, Y) \sim f(x, y), Z = g(X, Y)$ , 则

$$F_Z(z) = P(Z \leq z) = P(g(X, Y) \leq z) = \iint_{g(X, Y) \leq z} f(x, y) dx dy$$

进而,  $f_Z(z) = F'_Z(z)$  即得概率密度函数。

**$Z = X + Y$  的密度函数**

$$F_Z(z) = P(X + Y \leq z) = \int_{x+y \leq z} f(x, y) dx dy = \int_{-\infty}^{+\infty} dx \int_{-\infty}^{z-x} f(x, y) dy$$
$$f_Z(z) = F'_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x) dx = \int_{-\infty}^{+\infty} f(z-y, y) dy$$

当  $X, Y$  独立时,  $f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) = (f_X * f_Y)(z)$  为**卷积**。

**正态分布的可加性** 若  $X, Y$  独立, 且  $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$ , 那么  $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ 。

**$Z = X/Y$  的密度函数**

$$F_Z(z) = P(X/Y \leq z) = \int_{x/y \leq z} f(x, y) dx dy = \int_0^{+\infty} \int_{-\infty}^{yz} f(x, y) dx dy + \int_{-\infty}^0 \int_{yz}^{+\infty} f(x, y) dx dy$$
$$f_Z(z) = F'_Z(z) = \int_0^{+\infty} y f(yz, y) dy - \int_{-\infty}^0 y f(yz, y) dy = \int_{-\infty}^{+\infty} |y| f(yz, y) dy$$

**$Z = X^2 + Y^2$  密度函数**

$$F_Z(z) = P(X^2 + Y^2 \leq z) = \iint_{x^2+y^2 \leq z} f(x, y) dx dy = \int_0^{\sqrt{z}} r dr \int_0^{2\pi} f(r \cos \theta, r \sin \theta) d\theta \quad (z \geq 0)$$

$$f_Z(z) = F'_Z(z) = \frac{1}{2} \int_0^{2\pi} f(\sqrt{z} \cos \theta, \sqrt{z} \sin \theta) d\theta \quad (z \geq 0)$$

特别地,  $n$  个独立的标准正态分布的平方和为自由度为  $n$  的**卡方分布**。

$M = \max(X, Y), m = \min(X, Y)$  **极值分布**

$$F_M(z) = P(\max(X, Y) \leq z) = P(X \leq z, Y \leq z) = F(z, z)$$

$$F_m(z) = P(\min(X, Y) \leq z) = 1 - P(X > z, Y > z)$$

注 可以推广至  $n$  个变量的极值分布。

## 4 随机变量的数字特征

### 数学期望

**离散型随机变量的数学期望** 设  $X$  为离散型随机变量, 其分布律为  $P(X = x_k) = p_k \quad (k = 1, 2, \dots)$ , 若无穷级数  $\sum_{k=1}^{+\infty} p_k x_k$  绝对收敛, 则称其和为随机变量  $X$  的数学期望, 记为  $EX = \sum_{k=1}^{+\infty} p_k x_k$ 。

**二项分布的数学期望**

$$X \sim B(n, p)$$

$$EX = \sum_{k=0}^n k C_n^k p^k (1-p)^{n-k} = \sum_{k=1}^n n \frac{(n-1)!}{(n-k)!(k-1)!} p \cdot p^{k-1} (1-p)^{n-k} = np \sum_{k=1}^n C_{n-1}^{k-1} p^{k-1} (1-p)^{n-k}$$

$$EX = np \sum_{k=0}^{n-1} C_{n-1}^k p^k (1-p)^{n-1-k} = np$$

**泊松分布的数学期望**

$$X \sim P(\lambda)$$

$$EX = \sum_{i=0}^{\infty} i \cdot \frac{\lambda^i}{i!} e^{-\lambda} = e^{-\lambda} \lambda \sum_{i=1}^{\infty} \frac{\lambda^{i-1}}{(i-1)!} = \lambda e^{-\lambda} \sum_{i=0}^{+\infty} \frac{\lambda^i}{i!} = e^{-\lambda} \lambda e^{\lambda} = \lambda$$

**连续型随机变量的数学期望** 设连续型随机变量的概率密度为  $f(x)$ , 若积分  $\int_{-\infty}^{+\infty} x f(x) dx$  绝对收敛, 则称此积分的值为  $X$  的数学期望, 记作  $EX = \int_{-\infty}^{+\infty} x f(x) dx$ 。

**正态分布的数学期望** 若  $X \sim N(\mu, \sigma^2)$ , 则  $EX = \mu$ 。

**均匀分布的数学期望** 若  $X \sim U(a, b)$ , 则  $EX = \frac{a+b}{2}$ 。

**指数分布的数学期望** (利用分部积分)

$$X \sim E(\lambda)$$

$$EX = \int_0^{+\infty} x f(x) dx = \int_0^{+\infty} x \cdot \lambda e^{-\lambda x} dx = \dots = \frac{1}{\lambda}$$

**随机变量函数的期望** 设  $Y$  为  $X$  的分段连续函数, 若  $Y = g(X)$ ,  $E(Y)$  存在, 则

- 对离散型随机变量  $X$ , 若  $P(X = x_k) = p_k$ , 则  $EY = E(g(X)) = \sum_k g(x_k) p_k$ ;
- 对连续型随机变量  $X$ , 若概率密度为  $f(x)$ , 则  $EY = E(g(X)) = \int_{-\infty}^{+\infty} g(x) f(x) dx$ 。

设  $Z$  为  $X, Y$  的函数,  $Z = g(X, Y)$  且  $g$  连续, 则

- 对离散型随机变量,  $EZ = \sum_i \sum_j g(x_i, y_j) p_{i,j}$ ;
- 对连续型随机变量,  $EZ = \iint_{\mathbb{R}^2} g(x, y) f(x, y) dx dy$ 。

## 几个重要的随机变量函数期望的定义

- $k$  阶原点矩:  $E(X^k)$ ;
- $k$  阶绝对原点矩:  $E(|X|^k)$ ;
- $k$  阶中心矩:  $E((X - EX)^k)$ ;
- 方差 (2 阶中心矩):  $E((X - EX)^2)$ ;
- 偏度 (3 阶中心矩):  $E((X - EX)^3)$ ;
- 峰度 (4 阶中心矩):  $E((X - EX)^4)$ 。

**数学期望的性质** 设  $X, Y$  为随机变量,  $a, b, c$  为常数

- $X$  期望存在  $\iff E(|X|) < +\infty$ ;
- $X \leq Y$ , 则  $E(X) \leq E(Y)$ ;
- $a \leq X \leq b$ , 则  $a \leq E(X) \leq b$ ;
- **线性性**:  $E(aX + bY + c) = aE(X) + bE(Y) + c$ ;  
**线性性推广**:  $E(\sum_{i=1}^n a_i X_i) = \sum_{i=1}^n a_i E(X_i)$ ;
- 若  $X, Y$  独立, 则  $E(XY) = E(X)E(Y)$ , **逆命题不真**;  
**推广**: 若  $X_1, X_2, \dots, X_n$  相互独立, 则  $E(\prod_{i=1}^n X_i) = \prod_{i=1}^n E(X_i)$ 。

## 方差

设  $X$  为随机变量, 若  $EX^2$  绝对可积, 则称  $E(X - EX)^2$  为  $X$  的**方差**, 记为  $DX$ , 反映了  $X$  偏离均值程度。

**标准差** (均方差) 定义为:  $\sigma_X = \sqrt{DX}$ 。

### 计算方法

$$DX = E(X - EX)^2 = E(X^2 - 2EX \cdot X + (EX)^2) = E(X^2) - (EX)^2$$

- 由于  $DX \geq 0$ , 有  $E(X^2) \geq (EX)^2$ 。
- 可以通过  $EX, DX$  计算  $EX^2$ :  $EX^2 = (EX)^2 + DX$ 。

### 二项分布的方差

$$X \sim B(n, p)$$

$$EX^2 = \sum_{k=0}^n k^2 C_n^k p^k (1-p)^{n-k} = \sum_{k=2}^n k(k-1) \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} + \sum_{k=1}^n k \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$$

$$EX^2 = n(n-1)p^2 + np$$

$$DX = EX^2 - (EX)^2 = n(n-1)p^2 + np - n^2p^2 = np - np^2 = np(1-p)$$

### 泊松分布的方差

$$X \sim P(\lambda)$$

$$DX = EX^2 - (EX)^2 = \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!} e^{-\lambda} - \lambda^2 = e^{-\lambda} \left( \lambda^2 \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} + \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \right) - \lambda^2$$

$$DX = \lambda^2 + \lambda - \lambda^2 = \lambda$$

**正态分布的方差** 若  $X \sim N(\mu, \sigma^2)$ , 则  $DX = \sigma^2$ 。

**均匀分布的方差** 若  $X \sim U(a, b)$ , 则  $DX = \frac{(b-a)^2}{12}$ 。

**指数分布的方差** (利用分部积分)

$$X \sim E(\lambda)$$

$$DX^2 = \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx - \left(\frac{1}{\lambda}\right)^2 = \dots = \frac{1}{\lambda^2}$$

**方差的性质** 设  $X, Y$  为随机变量,  $a, b, c$  为常数。

- $D(c) = 0$ ;
- $D(cX) = c^2 D(X)$ ;
- 若  $X, Y$  独立, 则  $D(X \pm Y) = D(X) + D(Y)$ ;
- 一般地,  $D(X \pm Y) = DX + DY \pm 2E((X - EX)(Y - EY))$  (协方差) ;
- 若  $X_1, X_2, \dots, X_n$  相互独立, 则  $D(\sum_{i=1}^n a_i X_i) = \sum_{i=1}^n a_i^2 D(X_i)$ ;
- $D(X) = E(X - EX)^2 \leq E(X - a)^2$   
证明:  $g(c) = E(X - c)^2 = E(X^2) - 2cEX + c^2$ , 当  $c = EX$  时  $g(c)$  最小。
- $DX = 0 \iff \exists c, P(X = c) = 1$  (几乎处处是常数) 。

**标准化随机变量** 随机变量  $X$  的标准化随即变量  $X^*$  定义为:

$$X^* = \frac{X - EX}{\sqrt{DX}} \quad (DX > 0)$$

那么,  $E(X^*) = 0, D(X^*) = 1$ 。

## 协方差和相关系数

**协方差** 若  $X, Y$  为随机变量, 定义 **协方差** 为  $\text{cov}(X, Y) = E(X - EX)(Y - EY)$ 。特别地,  $DX = \text{cov}(X, X)$ 。称半正定矩阵  $A \in \mathbb{R}^{2 \times 2}$  为  $X, Y$  的**协方差矩阵**, 其中  $a_{1,1} = D(X)$ ,  $a_{2,2} = D(Y)$ ,  $a_{1,2} = a_{2,1} = \text{cov}(X, Y) = \text{cov}(Y, X)$ 。

一般地,  $n$  维随机变量  $(X_1, X_2, \dots, X_n)$  存在实对称半正定协方差矩阵  $\Sigma_n = (\text{cov}(X_i, X_j))_{n \times n}$ 。

**相关系数** 若  $X, Y$  为随机变量且  $DX > 0, DY > 0$ , 则相关系数  $\rho_{X,Y}$  定义为:

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sqrt{DX}\sqrt{DY}}$$

- 相关系数  $\rho_{X,Y}$  为无量纲量;
- $|\rho_{X,Y}|$  的大小反映了  $X, Y$  背后的线性关系的强弱。

**协方差的计算**

- 利用定义, 计算  $E(X - EX)(Y - EY)$ ;
- 用公式计算:  $E(X - EX)(Y - EY) = E(XY) - EX \cdot EY$ 。

**协方差的性质**

- **对称性:**  $\text{cov}(X, Y) = \text{cov}(Y, X)$ ;
- $\text{cov}(aX, bY) = ab\text{cov}(X, Y)$ ;
- $\text{cov}(X + Y, Z) = \text{cov}(X, Z) + \text{cov}(Y, Z)$ ;
- $\text{cov}(X, X) = DX$ ;
- $\text{cov}(aX + bY, cX + dY) = acDX + (bc + ad)\text{cov}(X, Y) + bdDY$ ;
- $D(aX + bY) = \text{cov}(aX + bY, aX + bY) = a^2 DX + b^2 DY + 2ab\text{cov}(X, Y)$ 。

**Cauchy-Schwartz不等式**

$$\text{cov}^2(X, Y) \leq DXDY$$

证明:  $f(t) = D(X + tY) = (DX)^2 + 2t\text{cov}(X, Y) + t^2(DY)^2 \geq 0$ , 故

$$\Delta = 4\text{cov}^2(X, Y) - 4DXDY \leq 0$$

当  $t = t^* = -\frac{\text{cov}(X, Y)}{DY}$  时,  $D(X + tY)$  最小值  $D(X + t^*Y) = DX(1 - \rho_{X, Y}^2)$ 。

**二维正态分布的相关系数** 若  $(X, Y) \sim N(\mu_1, \sigma_1; \mu_2, \sigma_2; \rho)$ , 则  $\rho_{X, Y} = \rho$ 。

### 相关系数的性质

- $|\rho_{X, Y}| \leq 1$  (由 Cauchy-Schwartz 不等式直接导出) ;
- $\rho_{X, Y} = 0$  称  $X, Y$  **不相关**;  $\rho_{X, Y} > 0$  称  $X, Y$  **正相关**;  $\rho_{X, Y} < 0$  称  $X, Y$  **负相关**;  $\rho_{X, Y} = 1$  称  $X, Y$  **完全正相关**;  $\rho_{X, Y} = -1$  称  $X, Y$  **完全负相关**。
- $|\rho_{X, Y}| = 1 \iff D(X + t^*Y) = DX(1 - \rho_{X, Y}^2) = 0 \iff \exists c, P(X + t^*Y = c) = 1$ , 几乎在一条直线上, 称**完全线性相关**。
- $X, Y$  不相关  
 $\iff \rho_{X, Y} = 0 \iff \text{cov}(X, Y) = 0 \iff E(XY) = EXEY \iff D(X \pm Y) = DX + DY$
- **【注】** 独立一定不相关, 不相关不一定独立! !
  - 对于二维正态分布  $N(\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho)$ ,  $X, Y$  独立  $\iff X, Y$  不相关  $\iff \rho = 0$

### Chebyshev 不等式

一般地, 有

$$P(|X - EX| \geq \varepsilon) \leq \frac{DX}{\varepsilon^2} \quad (\varepsilon > 0)$$

$$P(|X - EX| \leq \varepsilon) \geq 1 - \frac{DX}{\varepsilon^2} \quad (\varepsilon > 0)$$

证明:

$$P = P(|X - EX| \geq \varepsilon)$$
$$DX = \left( \int_{-\infty}^{EX-\varepsilon} + \int_{EX-\varepsilon}^{EX+\varepsilon} + \int_{EX+\varepsilon}^{+\infty} \right) (X - EX)^2 f(x) dx \geq \left( \int_{-\infty}^{EX-\varepsilon} + \int_{EX+\varepsilon}^{+\infty} \right) \varepsilon^2 f(x) dx = \varepsilon^2 P$$

## 5 大数定律与中心极限定理

### 大数定律

**Bernoulli大数定理** 设  $n_A$  为  $n$  次独立重复试验中事件  $A$  发生次数,  $p$  是每次试验中  $A$  发生的概率, 则  $\forall \varepsilon > 0$ ,

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{n_A}{n} - p\right| \geq \varepsilon\right) = 0$$

或

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{n_A}{n} - p\right| < \varepsilon\right) = 1$$

**依概率收敛** 设  $Y_1, Y_2, \dots, Y_n$  为一随机变量序列,  $a$  是一常数, 且  $\forall \varepsilon > 0$  有

$$\lim_{n \rightarrow \infty} P(|Y_n - a| \geq \varepsilon) = 0$$

或

$$\lim_{n \rightarrow \infty} P(|Y_n - a| < \varepsilon) = 1$$

则称随机变量序列  $Y_1, Y_2, \dots, Y_n$  依概率收敛至  $a$ , 记作  $Y_n \xrightarrow{p; n \rightarrow \infty} a$ 。

**服从大数定律** 若随机变量序列  $X_1, X_2, \dots, X_n$  具有如下性质则称这个随机变量序列服从大数定律:

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| < \varepsilon \right) = 1$$

即  $\frac{1}{n} \sum_{k=1}^n X_k$  依概率收敛到  $\frac{1}{n} \sum_{k=1}^n E(X_k)$ 。

若  $X_1, X_2, \dots, X_n$  独立同分布, 则上式等价于

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - EX \right| < \varepsilon \right) = 1$$

即  $\frac{1}{n} \sum_{k=1}^n X_k$  依概率收敛到  $EX$ 。

### Chebyshev 大数定律

设随机变量序列  $X_1, X_2, \dots, X_n$  两两不相关, 它们的方差存在, 而且有共同上界, 即

$$E(X_k) = \mu_k, \quad D(X_k) = \sigma_k^2 \leq \sigma^2 < +\infty \quad (k = 1, 2, \dots, n)$$

则这个随机变量序列服从大数定律, 即

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n \mu_k \right| < \varepsilon \right) = 1$$

证明: 令  $Y_n = \frac{1}{n} \sum_{k=1}^n X_k$ , 则  $E(Y_n) = \frac{1}{n} \sum_{k=1}^n \mu_k$ 。

$$D(Y_n) = \frac{1}{n^2} D \left( \sum_{i=1}^n X_i \right) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) \leq \frac{\sigma^2}{n^2} \cdot n = \frac{\sigma^2}{n}$$

根据 Chebyshev 不等式,  $P(|Y_n - E(Y_n)| < \varepsilon) \geq 1 - \frac{DY_n}{\varepsilon^2} = 1 - \frac{\sigma^2}{n\varepsilon^2} \rightarrow 1 \ (n \rightarrow \infty)$ 。

即满足大数定律。

**注意:** 所有条件可以削弱至 **Markov 条件**

$$\frac{1}{n^2} D \left( \sum_{k=1}^n X_k \right) \xrightarrow{n \rightarrow \infty} 0$$

**Khintchine 大数定律** 设  $X_1, X_2, \dots, X_n$  独立同分布, 若它们期望存在,  $E(X_i) = \mu$ , 则该序列服从大数定律, 即  $\frac{1}{n} \sum_{k=1}^n X_k$  依概率收敛到  $\mu$ , 即

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| < \varepsilon \right) = 1$$

## 中心极限定理

**Lindeberg-L é vy 中心极限定理** 设  $X_1, X_2, \dots, X_n$  独立同分布, 且

$$E(X_i) = \mu, \quad D(X_i) = \sigma^2 < +\infty$$

则  $\forall x$ ,

$$\lim_{n \rightarrow \infty} P \left( \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x \right) = \Phi(x)$$

即  $\sum_{i=1}^n X_i$  近似服从  $N(n\mu, n\sigma^2)$ ,  $Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$  在  $n$  很大时近似服从于  $N(0, 1)$ 。

## 6 数理统计的基本概念

### 总体与样本

**总体** 研究对象的全体（研究对象某项数量指标的全体）组成的集合。

**个体** 组成总体的每一个个体。

**总体分布** 总体中每个个体数量指标不同，背后有一定的分布，称为总体分布。（把总体看成一个随机变量  $X$ ，总体分布即是随机变量  $X$  的分布）。

**样本** 从总体中随机抽取部分个体组成的集合称为样本  $(X_1, X_2, \dots, X_n)$ ， $n$  称为**样本容量**。

**样本值**（样本观察值） $(x_1, x_2, \dots, x_n)$  称为总体  $X$  的一个容量为  $n$  的样本观察值，即样本的一组可能取值。

**样本空间** 样本  $(X_1, X_2, \dots, X_n)$  的所有可能取值的集合，记作  $\mathcal{X}$ 。

**简单随机样本**（如不加特别说明，样本默认为简单随机样本）设  $(X_1, X_2, \dots, X_n)$  为来自  $X$  的一个样本，若其满足

- $X_1, X_2, \dots, X_n$  与  $X$  同分布；
- $X_1, X_2, \dots, X_n$  相互独立；

则称这个样本是简单随机样本。

- 简单随机样本  $(X_1, X_2, \dots, X_n)$  的联合分布函数  $F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F_X(x_i)$ ；
- 简单随机样本  $(X_1, X_2, \dots, X_n)$  的联合密度函数  $f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_X(x_i)$ ；

**统计量** 若  $g(x_1, x_2, \dots, x_n)$  是不含未知参数的实值连续函数，则随机变量  $g(X_1, X_2, \dots, X_n)$  为统计量， $(x_1, x_2, \dots, x_n)$  为样本  $(X_1, X_2, \dots, X_n)$  观察值，则  $g(x_1, x_2, \dots, x_n)$  为统计量  $g(X_1, X_2, \dots, X_n)$  观察值。

#### 常用的一些统计量

- 样本均值  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ，依概率收敛至  $EX$ ；
- 样本方差  $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ，依概率收敛至  $DX$ ；
- 样本均方差  $s = \sqrt{s^2}$ ，依概率收敛至  $\sqrt{DX}$ ；
- 样本  $k$  阶矩  $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ ，依概率收敛至  $E(X^k)$ ；
- 样本  $k$  阶中心矩  $CM_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ ，依概率收敛至  $E((X - EX)^k)$ 。
- 顺序统计量：将  $(X_1, X_2, \dots, X_n)$  从小到大排序后得到  $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ ，即为**顺序统计量**， $X_{(1)} = \min_{i=1}^n X_i$ ,  $X_{(n)} = \max_{i=1}^n X_i$ ，**极差**  $D = X_{(n)} - X_{(1)}$ 。

### 抽样分布

#### 正态分布

$$X \sim N(\mu, \sigma^2), \quad (X_1, X_2, \dots, X_n), \quad X_i \sim N(\mu, \sigma^2)$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\sum_{i=1}^n a_i X_i \sim N\left(\mu \sum_{i=1}^n a_i, \sigma^2 \sum_{i=1}^n a_i^2\right)$$

#### 卡方分布



设  $(X_1, X_2, \dots, X_n)$  独立同分布, 且  $X_i \sim N(0, 1)$ , 则  $\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2 = \sum_{i=1}^n X_i^2 \sim \chi^2(n)$ , 称  $\chi^2$  服从自由度为  $n$  的**卡方分布**。

**图像** (均在  $y$  轴右半边)

- $n = 1$  时候递减, 类似反比例函数;
- $n = 2$  时候递减,  $\chi^2(2) = E(\frac{1}{2})$ ;
- $n \geq 3$  时出现峰, 且  $n$  越大峰越靠后。

**性质**

- **可加性**: 若  $\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$  且  $\chi_1^2, \chi_2^2$  独立, 则  $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$ 。
- 若  $X \sim \chi^2(n)$ , 则 (利用了自由度为2的卡方分布是参数为  $\frac{1}{2}$  的指数分布)

$$EX = E(X_1^2 + X_2^2 + \dots + X_n^2) = \sum_{i=1}^n E(X_i^2) = n(EX_i + DX_i) = n(0 + 1) = n$$

$$DX = D(X_1^2 + X_2^2 + \dots + X_n^2) = nD(X_1^2) = \frac{n}{2}D(X_1^2 + X_2^2) = \frac{n}{2} \times \frac{1}{(\frac{1}{2})^2} = 2n$$

同时, 这个结果给出了对于服从标准正态分布  $N(0, 1)$  的随机变量  $X$  的平方的期望为1, 方差为2。

**查表**: 若  $P(X > k) = \alpha$ , 则记  $k = \chi_\alpha^2(n)$ , 称其为  $\alpha$ -分位数。

**t-分布**

设  $X \sim N(0, 1), Y \sim \chi^2(n)$ ,  $X, Y$  独立, 则

$$T = \frac{X}{\sqrt{\frac{Y}{n}}}$$

所服从的分布称为自由度为  $n$  的 t-分布。记为  $T \sim t(n)$ 。

**图像&性质**

- $f(t)$  为偶函数, 图像关于  $y$  轴对称;
- $n \rightarrow +\infty, T \stackrel{\text{近似}}{\sim} N(0, 1)$ 。(根据**Khinchine大数定律**,  $Y/n$  依概率收敛到  $E(Y_1^2) = 1$ 。

**查表**: 若  $P(T > k) = \alpha$ , 则记  $k = t_\alpha(n)$ , 称其为  $\alpha$ -分位数。

**F-分布**

设  $X \sim \chi^2(m), Y \sim \chi^2(n)$ , 且  $X, Y$  独立, 则

$$F = \frac{\frac{X}{m}}{\frac{Y}{n}}$$

服从的分布称为第一自由度  $m$ , 第二自由度  $n$  的 F-分布, 记为  $F \sim F(m, n)$ 。

**图像** 和卡方分布类似。

**性质**

- $F \sim F(m, n)$ , 则  $\frac{1}{F} \sim F(n, m)$ ;
- $T \sim t(n)$ , 则  $T^2 \sim F(1, n)$ 。

**查表**: 若  $P(F > k) = \alpha$ , 则记  $k = F_\alpha(m, n)$ , 称其为  $\alpha$ -分位数。

**分位数性质**

- $F_{1-\alpha}(m, n) = \frac{1}{F_{\alpha}(n, m)}$ ;

证明:  $X \sim F(m, n)$ , 令  $F_{1-\alpha}(m, n) = k$ , 则  $P(X > k) = 1 - \alpha$ , 从而  $P(X \leq k) = \alpha$ , 从而  $P\left(\frac{1}{X} \geq \frac{1}{k}\right) = \alpha$ , 而  $\frac{1}{X} \sim F(n, m)$ , 从而  $F_{\alpha}(n, m) = \frac{1}{k}$ , 从而  $F_{1-\alpha}(m, n) = \frac{1}{F_{\alpha}(n, m)}$ 。

- $[t_{1-\frac{\alpha}{2}}(n)]^2 = F_{\alpha}(1, n)$ ;

证明:  $X \sim t(n)$ , 设  $k = t_{1-\frac{\alpha}{2}}(n)$ , 则  $P(X > k) = 1 - \frac{\alpha}{2}$ 。容易知道  $k \leq 0$  (因为  $P(X > k) \geq \frac{1}{2}$ , t-分布具有对称性), 从而  $P(X \leq k) = \frac{\alpha}{2}$ ,  $P(|X| > -k) = \alpha$ ,  $P(X^2 > k^2) = \alpha$ 。又  $X^2 \sim F(1, n)$ , 从而  $k^2 = F_{\alpha}(1, n)$ , 于是  $[t_{1-\frac{\alpha}{2}}(n)]^2 = F_{\alpha}(1, n)$ 。

## 正态总体的抽样分布

### 一个正态总体的抽样分布

$$X \sim N(\mu, \sigma^2), \quad EX = \mu, \quad DX = \sigma^2, \quad (X_1, X_2, \dots, X_n)$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n)$$

$$\frac{n-1}{\sigma^2} s^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$$

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

$$\frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} = \frac{\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{1}{n-1} \cdot \frac{n-1}{\sigma^2} s^2}} \sim t(n-1)$$

重要性质:  $\bar{X}$  和  $s$  相互独立。

### 两个独立正态总体的分布情况 ( $X, Y$ 独立)

$$X \sim N(\mu_1, \sigma_1^2), \quad Y \sim N(\mu_2, \sigma_2^2), \quad (X_1, X_2, \dots, X_n), \quad (Y_1, Y_2, \dots, Y_m)$$

$$\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right)$$

若  $\sigma_1 = \sigma_2 = \sigma$ , 则

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{1}{n} + \frac{1}{m}} \sigma} \sim N(0, 1)$$

$$s_w = \sqrt{\frac{n-1}{n+m-2} s_1^2 + \frac{m-1}{n+m-2} s_2^2}$$

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{1}{n} + \frac{1}{m}} s_w} = \frac{\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{1}{n} + \frac{1}{m}} \sigma}}{\sqrt{\frac{1}{n+m-2} \left(\frac{n-1}{\sigma_1^2} s_1^2 + \frac{m-1}{\sigma_2^2} s_2^2\right)}} \sim t(n+m-2)$$

另外还有

$$\frac{\frac{s_1^2}{\sigma_1^2}}{\frac{s_2^2}{\sigma_2^2}} = \frac{\frac{1}{n-1} \frac{n-1}{\sigma_1^2} s_1^2}{\frac{1}{m-1} \frac{m-1}{\sigma_2^2} s_2^2} \sim F(n-1, m-1)$$

$$\frac{s_1^2}{s_2^2} \sim F(n-1, m-1) \quad (\sigma_1^2 = \sigma_2^2)$$

## 7 参数估计

### 点估计法

设总体  $X \sim F(x; \theta_1, \theta_2, \dots, \theta_k)$ , 其中  $\theta_1, \theta_2, \dots, \theta_k$  为未知参数。用  $k$  个统计量估计  $\theta_1, \theta_2, \dots, \theta_k$  的方法称为**点估计法**。

### 矩法

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n X_i &= \bar{X} \approx EX = \mu_1(\theta_1, \theta_2, \dots, \theta_k) \\ \frac{1}{n} \sum_{i=1}^n X_i^2 &= M_2 \approx EX^2 = \mu_2(\theta_1, \theta_2, \dots, \theta_k) \\ &\dots \\ \frac{1}{n} \sum_{i=1}^n X_i^k &= M_k \approx EX^k = \mu_k(\theta_1, \theta_2, \dots, \theta_k) \end{aligned}$$

一般地,

$$\begin{aligned} \hat{\mu} &= \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = CM_2 \end{aligned}$$

注: 如果上述  $k$  个方程中有无用方程(恒等), 则继续往下列写, 直到有 7

### 极大似然估计

**离散型下的似然函数** 一般地, 设  $X$  为离散型总体, 其分布律为

$P(X = x) = p(x; \theta) \ (x = \mu_1, \mu_2, \dots, \mu_m, \dots), \ (X_1, X_2, \dots, X_n)$  为总体样本, 似然函数如下定义:

$$P(X = x_1, X = x_2, \dots, X = x_n) = \prod_{i=1}^n P(X = x_i) = \prod_{i=1}^n p(x_i; \theta) \stackrel{def}{=} L(x_1, x_2, \dots, x_n; \theta)$$

**离散型下的对数似然函数** 一般地, 对数似然函数如下定义:

$$\ln L(x_1, x_2, \dots, x_n; \theta) = \sum_{i=1}^n \ln p(x_i; \theta)$$

**连续型下的似然函数** 类似地, 似然函数如下定义:

$$L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) \stackrel{def}{=} \prod_{i=1}^n f(x_i; \theta_1, \theta_2, \dots, \theta_k)$$

**连续型下的对数似然函数** 一般地, 对数似然函数如下定义:

$$\ln L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) = \sum_{i=1}^n \ln f(x_i; \theta_1, \theta_2, \dots, \theta_k)$$

**方法** 寻找  $\theta = \hat{\theta}$ , 使得似然函数 (或对数似然函数)  $L(\theta)$  (或  $\ln L(\theta)$ ) 取极大值, 即

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} \left\{ \prod_{i=1}^n p(x_i; \theta) \right\}$$

则称这样得到的  $\hat{\theta} = g(x_1, x_2, \dots, x_n)$  即为参数的估计值,  $g(X_1, X_2, \dots, X_n)$  为**极大似然估计量**。

若有多个参数, 则对于每个参数求偏导后令其等于0得到一个方程, 联立解出估计值即可。

**极大似然估计的不变性原理** 设  $\hat{\theta}$  为  $\theta$  的极大似然估计量,  $u(\theta)$  为  $\theta$  的连续函数, 则  $u(\hat{\theta})$  也为  $u(\theta)$  的极大似然估计量。

**泊松分布总体的极大似然估计** 设  $X \sim P(\lambda)$ , 样本  $(X_1, X_2, \dots, X_n)$ , 则经过极大似然估计后, 有

$$\lambda = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

**正态总体的极大似然估计** 设  $X \sim N(\mu, \sigma^2)$ , 样本  $(X_1, X_2, \dots, X_n)$ , 则经过极大似然估计后, 有

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$
$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

## 估计量的评判标准

### 无偏性

设总体  $X \sim F(x; \theta)$ ,  $\theta$  为位置参数,  $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$  为  $\theta$  的估计量 (是一个统计量!), 若对任意设定的  $\theta$  都有  $E(\hat{\theta}) = \theta$ , 则说  $\hat{\theta}$  为  $\theta$  的**无偏估计量**。

**同一个参数的无偏估计量不唯一**

- $\bar{X}$  为  $EX$  无偏估计,  $\frac{1}{n} \sum_{i=1}^n X_i^k$  为  $EX^k$  无偏估计;
- $CM_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  不是正态总体  $N(\mu, \sigma^2)$  中  $\sigma^2$  的无偏估计,  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  是  $\sigma^2$  的无偏估计。

### 有效性

设  $\hat{\theta}_1, \hat{\theta}_2$  都是  $\theta$  的无偏估计量 (是统计量!), 若  $D(\hat{\theta}_1) < D(\hat{\theta}_2)$ , 则称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  有效。

**Rao-Cramer不等式** 若  $\hat{\theta}$  为  $\theta$  的无偏估计量, 则

$$D(\hat{\theta}) \geq \frac{1}{nE\left[\frac{\partial}{\partial\theta}\ln p(X, \theta)\right]^2} \stackrel{def}{=} D_0$$

**有效估计量** 能达到 Rao-Crammer 不等式下界的估计量。

### 一致性

设  $\hat{\theta}_n = \hat{\theta}(X_1, X_2, \dots, X_n)$  为  $\theta$  估计量, 若对任意  $\theta$ , 当  $n \rightarrow \infty$  时,  $\theta_n$  依概率收敛至  $\theta$ , 即

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \varepsilon) = 0 \quad (\varepsilon > 0)$$

则称  $\hat{\theta}_n$  为  $\theta$  的**一致估计量**。

- $M_k$  为  $EX^k$  的一致估计量。
- 矩估计量一般是一致估计量。

- 若  $\hat{\theta}$  是  $\theta$  的一致估计量,  $u$  为  $\theta$  的连续函数, 则  $u(\hat{\theta})$  为  $u(\theta)$  的一致估计量。
- $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  是总体方差的一致估计量。

## 区间估计

设  $X \sim F(x, \theta)$ ,  $\theta$  未知参数, 给定置信度为  $1 - \alpha$  ( $0 < \alpha < 1$ ), 若  $\exists \hat{\theta}_1, \hat{\theta}_2$ , 使得  $P(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2) = 1 - \alpha$ , 则称区间  $[\hat{\theta}_1, \hat{\theta}_2]$  为参数  $\theta$  的置信度为  $1 - \alpha$  的**置信区间**。

- 置信区间长度  $\hat{\theta}_2 - \hat{\theta}_1$  反映了估计精度, 长度越小精度越高;
- 置信度  $1 - \alpha$  反映了可靠度,  $\alpha$  越小精度越高;
- 先保证可靠性再提高精度, 通常  $1 - \alpha = 0.95$ ;
- 扩大样本容量可以提高精度。

### 一般方法

- 构造枢轴量 (仅含有待估参数  $\theta$ , 分布确定且不依赖于待估参数)  $g(X_1, X_2, \dots, X_n; \theta)$ ;
- 给定置信度  $1 - \alpha$ , 定出常数  $a, b$  使得  $P(a < g(X_1, X_2, \dots, X_n; \theta) < b) = 1 - \alpha$  ( $a, b$  不唯一);
- 反解不等式  $a < g(X_1, X_2, \dots, X_n; \theta) < b$  得到  $\hat{\theta}_1 < \theta < \hat{\theta}_2$ 。

### 一个正态总体的区间估计

- $\sigma^2$  已知, 求  $\mu$  区间估计, 枢轴量

$$U = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

- $\sigma^2$  未知, 求  $\mu$  区间估计, 枢轴量

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim t(n-1)$$

- $\mu$  已知, 求  $\sigma^2$  区间估计, 枢轴量

$$K = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$$

- $\mu$  未知, 求  $\sigma^2$  区间估计, 枢轴量

$$K = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$$

**单侧置信区间** 对于给定  $\alpha$ ,  $\theta$  待估, 若存在  $\underline{\theta}$  使得  $P(\underline{\theta} \leq \theta) = 1 - \alpha$ , 则称  $(\underline{\theta}, +\infty)$  为  $\theta$  的**单侧置信区间**,  $\underline{\theta}$  为**置信下限**; 同理有**置信上限**和另一个**单侧置信区间**。

### 两个正态总体的参数估计 ( $X, Y$ 独立)

$$X \sim N(\mu_1, \sigma_1^2), \quad Y \sim N(\mu_2, \sigma_2^2), \quad (X_1, X_2, \dots, X_n), \quad (Y_1, Y_2, \dots, Y_m)$$

- $\sigma_1, \sigma_2$  已知, 求  $(\mu_1 - \mu_2)$  置信区间, 枢轴量

$$U = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1)$$

- $\sigma_1, \sigma_2$  未知, 但有  $\sigma_1^2 = \sigma_2^2$ , 求  $(\mu_1 - \mu_2)$  置信区间, 枢轴量

$$s_w = \sqrt{\frac{n-1}{n+m-2} s_1^2 + \frac{m-1}{n+m-2} s_2^2}$$

$$T = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{s_w \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t(n+m-2)$$

- $\sigma_1, \sigma_2$  未知, 大样本, 可以近似估计  $\hat{\sigma}_1^2 = s_1^2, \hat{\sigma}_2^2 = s_2^2$  后利用  $U \sim N(0, 1)$ 。
- $\mu_1, \mu_2$  不要求, 求  $\frac{\sigma_1^2}{\sigma_2^2}$  置信区间, 枢轴量

$$F = \frac{\frac{s_1^2}{s_2^2}}{\frac{\sigma_1^2}{\sigma_2^2}} = \frac{\frac{1}{n-1} \frac{n-1}{\sigma_1^2} s_1^2}{\frac{1}{m-1} \frac{m-1}{\sigma_2^2} s_2^2} \sim F(n-1, m-1)$$

## 8 假设检验

对一个或多个总体的分布或参数作假设。从总体中抽样, 用统计的方法对假设合理性做出判断, 这类方法称作**假设检验** (统计假设检验)。假设检验分为参数检验和非参数检验。其理论依据为: 实际推断原理 (小概率原理), 即小概率事件在一次试验中不会发生。

### 一般方法

- 建立假设,  $H_0$  为原假设 (偶然因素导致的为原假设, 一般为题目所问),  $H_1$  为备选假设 ( $H_0, H_1$  不能交换且  $H_0, H_1$  互斥但并集为全集); 如果  $H_0$  涉及到复合假设如  $H_0: \mu \geq 70$ , 应该简单化得到  $H_0: \mu = 70$ 。
- 选择适当统计量  $T = g(X_1, X_2, \dots, X_n)$  (要求  $H_0$  成立条件下,  $T$  的分布完全已知); 给定显著性水平  $\alpha$ , 依据  $P_{H_0}(T \in W) \leq \alpha$  构造拒绝域  $W$ 。
- 代入数据检验:  $\hat{T} = g(X_1, X_2, \dots, X_n)$ , 如果  $\hat{T} \in W$ , 则拒绝  $H_0$ ; 否则接受  $H_0$ 。

### 注意

- 拒绝域由备选假设决定,  $\alpha$  越大越容易拒绝;
- 两类错误:
  - 第一类错误: 拒绝  $H_0$  但是  $H_0$  为真;
  - 第二类错误: 接受  $H_0$  但是  $H_0$  为假;
  - 犯第一类错误概率减小必然导致犯第二类错误概率增大, 反之亦然;
  - 应该尽可能避免犯第一类错误, 控制犯第一类错误的概率为  $\alpha$ ;
  - 要使犯两类错误概率都减小——扩大样本容量。

### 一个正态总体的参数检验

- 关于  $\mu$  检验:  $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$ :
  - 方差  $\sigma^2$  已知, 则

$$U = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \stackrel{H_0}{\sim} N(0, 1)$$

称为 U-检验法;

- 方差  $\sigma^2$  未知, 则

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \stackrel{H_0}{\sim} t(n-1)$$

称为 T-检验法;

- 关于  $\sigma^2$  的检验:  $H_0: \sigma^2 = \sigma_0^2, H_1: \sigma^2 \neq \sigma_0^2$ :
  - 均值  $\mu$  已知, 则

$$K = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \stackrel{H_0}{\sim} \chi^2(n)$$

- 均值  $\mu$  未知, 则

$$K = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \stackrel{H_0}{\sim} \chi^2(n-1)$$

上述均称为 K-检验法。

**两个正态总体的参数检验** ( $X, Y$  独立)

$$X \sim N(\mu_1, \sigma_1^2), \quad Y \sim N(\mu_2, \sigma_2^2), \quad (X_1, X_2, \dots, X_n), \quad (Y_1, Y_2, \dots, Y_m)$$

- 检验  $(\mu_1 - \mu_2)$ ,  $H_0: \mu_1 - \mu_2 = \delta, H_1: \mu_1 - \mu_2 \neq \delta$ 。

- $\sigma_1, \sigma_2$  已知, 则

$$U = \frac{\bar{X} - \bar{Y} - \delta}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \stackrel{H_0}{\sim} N(0, 1)$$

- $\sigma_1, \sigma_2$  未知, 但有  $\sigma_1^2 = \sigma_2^2$ , 则

$$s_w = \sqrt{\frac{n-1}{n+m-2} s_1^2 + \frac{m-1}{n+m-2} s_2^2}$$

$$T = \frac{\bar{X} - \bar{Y} - \delta}{s_w \sqrt{\frac{1}{n} + \frac{1}{m}}} \stackrel{H_0}{\sim} t(n+m-2)$$

- 检验  $\frac{\sigma_1^2}{\sigma_2^2}$ ,  $H_0: \frac{\sigma_1^2}{\sigma_2^2} = \delta, H_1: \frac{\sigma_1^2}{\sigma_2^2} \neq \delta$ , 则

$$F = \frac{1}{\delta} \frac{s_1^2}{s_2^2} \sim F(n-1, m-1)$$

称为 F-检验法。